

Nhận Diện Đề Cập Thực Thể và Giải Quyết Đồng Tham Chiếu trong Văn Bản Kể Chuyện Tiếng Việt

Đặng Hoàng Gia Khiêm^{1,2,3}, Võ Ngọc Anh Thy^{1,2,4}, Đinh Bảo Thy^{1,2,5}

¹Trường Đại học Công nghệ Thông tin, Thành phố Hồ Chí Minh, Việt Nam

²Đại Học Quốc Gia, Thành phố Hồ Chí Minh, Việt Nam

Email: { ³23520728, ⁴23521565, ⁵23521563 }@gm.uit.edu.vn

Tóm tắt—Nghiên cứu này tập trung vào bài toán giải quyết đồng tham chiếu trong văn bản kể chuyện tiếng Việt, với mục tiêu nhận diện đề cập thực thể và liên kết các đề cập khác nhau đến cùng một thực thể chung. Chúng tôi đề xuất một quy trình xử lý nối tiếp, trong đó các mô hình ngôn ngữ tiền huấn luyện được sử dụng để xây dựng biểu diễn ngữ nghĩa cho văn bản. Trên cơ sở đó, hệ thống có khả năng xác định và liên kết chính xác các đề cập đến cùng một thực thể trong ngữ cảnh kể chuyện. Kết quả thực nghiệm cho thấy phương pháp đề xuất cải thiện hiệu quả xử lý so với các cách tiếp cận trước đây.

Từ khóa—coreference resolution, mention detection, Vietnamese narrative texts

Ngày hôm sau **minh** vẫn đi học bình thường. **bố mẹ** đi làm xa nên **minh** chẳng kể cho ai. **Minh** dần thu **bản thân** lại, chỉ sống một mình một thế giới. Đỉnh điểm là năm sau, khi **cô giáo** cho **minh** làm thủ quỹ, **bố mẹ** đi làm xa nên **minh** ăn vật **minh** không thiếu, nhưng cả lớp lại nghĩ **minh** lấy tiền của lớp để tiêu xài, không ai nói cho **minh** điều ấy cả, **mọi người** cô lập và tẩy chay **minh** chỉ vì suy diễn.

m1: minh, bản thân
m2: bố mẹ, bố mẹ
m3: cô giáo
m4: lớp, mọi người

Hình 1. Ví dụ đầu vào và đầu ra của mô hình

I. GIỚI THIỆU

A. Tổng quan và Bối cảnh

Trong lĩnh vực Xử lý ngôn ngữ tự nhiên, giải quyết đồng tham chiếu là một bài toán nền tảng, nhằm xác định các cụm từ khác nhau cùng đề cập đến một thực thể trong văn bản. Một số nghiên cứu gần đây đã khai thác các mô hình ngôn ngữ lớn cho tiếng Việt. Tuy nhiên, việc phụ thuộc vào các mô hình dạng prompt-based đặt ra hạn chế về khả năng kiểm soát, chi phí tính toán và tính phù hợp với dữ liệu miền hẹp, đặc biệt trong bối cảnh thiếu hụt tài nguyên của tiếng Việt.

B. Phương pháp tiếp cận

Nghiên cứu này kế thừa tập dữ liệu văn bản kể chuyện được xây dựng từ nguồn báo chính thống VnExpress, do Tran và các cộng sự [1] thực hiện, đồng thời đề xuất một hướng tiếp cận tập trung vào việc huấn luyện và tối ưu hóa hệ thống giải quyết đồng tham chiếu dựa trên kiến trúc encoder. Khác với cách tiếp cận dựa trên truy vấn mô hình ngôn ngữ lớn trong bài nghiên cứu [1], nghiên cứu này xây dựng liên kết các đề cập đồng tham chiếu dựa trên việc huấn luyện mô hình. Bằng cách tận dụng các mô hình ngôn ngữ tiền huấn luyện, hệ thống có khả năng học được các biểu diễn ngữ nghĩa đặc thù cho cấu trúc câu và ngữ cảnh của văn bản tự sự tiếng Việt.

C. Đóng góp của đề tài

Đóng góp của bài báo được tóm lược như sau:

- 1) Xây dựng một quy trình giải quyết đồng tham chiếu cho tiếng Việt dựa trên kiến trúc xử lý nối tiếp giữa nhận diện đề cập thực thể và giải quyết đồng tham chiếu.
- 2) Thực hiện huấn luyện và đánh giá các mô hình encoder-based trên tập dữ liệu văn bản kể chuyện được thừa kế.

- 3) Phân tích thực nghiệm cho thấy mô hình chuyên biệt mang lại hiệu quả ổn định và thời gian xử lý phù hợp so với các mô hình ngôn ngữ đa năng.


Ví dụ minh họa đầu vào và đầu ra của bài toán được thể hiện ở Hình 1.

Phần còn lại của bài báo được tổ chức như sau: Mục II trình bày các nghiên cứu liên quan về giải quyết đồng tham chiếu và xử lý văn bản kể chuyện. Tập dữ liệu, cách thức tiền xử lý và thiết lập huấn luyện được trình bày trong Mục III. Mục IV mô tả chi tiết kiến trúc hệ thống và quy trình giải quyết đồng tham chiếu được đề xuất. Kết quả thực nghiệm và phân tích được thảo luận trong Mục V. Cuối cùng, Mục VI tổng kết nghiên cứu và đề xuất các hướng phát triển trong tương lai.

II. CÔNG TRÌNH LIÊN QUAN

Trên thế giới, các nghiên cứu về đồng tham chiếu đã đạt được những bước tiến đáng kể, đặc biệt là đối với tiếng Anh nhờ sự hỗ trợ từ các bộ dữ liệu quy mô lớn như OntoNotes [2] và CoNLL-2012 [3]. Các kỹ thuật tiếp cận bài toán này vô cùng đa dạng, trải dài từ những phương pháp học máy truyền thống đến các mô hình mạng thần kinh hiện đại và kiến trúc Transformer chuyên sâu.

Đối với tiếng Việt, giải quyết đồng tham chiếu vẫn là một thách thức lớn do tính chất của một ngôn ngữ ít tài nguyên và sự khan hiếm các bộ dữ liệu gán nhãn chuẩn. Những nỗ lực gần đây đã bắt đầu tập trung vào việc thu hẹp khoảng cách này, tiêu biểu là nghiên cứu của Tran và các cộng sự [1]. Nhóm tác giả này đã xây dựng một bộ dữ liệu gán nhãn chi tiết cho các văn bản kể chuyện từ VnExpress và thiết lập các hướng dẫn gán nhãn đồng tham chiếu một cách chặt chẽ để đảm bảo tính chính xác. Công trình của họ tận dụng sức mạnh của các mô hình ngôn ngữ lớn (LLM) như GPT-3.5-Turbo và



Hình 2. Pipeline hệ thống

GPT-4 thông qua kỹ thuật học ít mẫu (few-shot learning). Kết quả thực nghiệm cho thấy GPT-4 vượt trội hoàn toàn về khả năng nhận diện và liên kết các thực thể phức tạp, đồng thời duy trì tính nhất quán cao hơn trong phản hồi so với các phiên bản tiền nhiệm.

Mặc dù các mô hình ngôn ngữ lớn (LLM) đã chứng minh tiềm năng to lớn trong việc xử lý các bài toán ngôn ngữ với ít dữ liệu gán nhãn, xu hướng huấn luyện các mô hình mã hóa chuyên biệt (encoder-based) vẫn giữ vai trò quan trọng nhờ tính ổn định và khả năng tùy chỉnh cao. Nhiều nghiên cứu đồng tham chiếu trên tiếng Anh có xu hướng sử dụng các mô hình encoder-based [4], chỉ ra rằng kiến trúc bộ mã hóa có khả năng nắm bắt tốt hơn các sắc thái ngữ nghĩa của ngôn ngữ thông qua việc học các biểu diễn ngữ nghĩa dày đặc.

III. BỘ DỮ LIỆU

Trong nghiên cứu này, chúng tôi sử dụng tập dữ liệu được kế thừa từ bài báo *Coreference Resolution for Vietnamese Narrative Texts* [1]. Dữ liệu được xây dựng từ các đoạn văn bản thu thập từ VnExpress, một trong những nền tảng tin tức trực tuyến tiếng Việt phổ biến nhất, bao gồm các chủ đề như mối quan hệ, đời sống hàng ngày, công việc và các kết nối xã hội khác.

Dữ liệu kế thừa được cung cấp dưới hai thiết lập.

- Thiết lập thứ nhất phục vụ in-context learning, bao gồm 5 file train là ví dụ cho LLM, 75 văn bản validate và 183 văn bản test.
- Thiết lập thứ hai là few-shot, trong đó mỗi tập train, validation và test chỉ bao gồm 1 văn bản, nhằm đánh giá khả năng tổng quát hóa của mô hình trong bối cảnh dữ liệu hạn chế.

Để phù hợp với bài toán mới - supervised learning, tập dữ liệu $\mathcal{D}$ được phân chia ngẫu nhiên thành ba tập con theo tỷ lệ 70/10/20 cho $\mathcal{D}_{train}$, $\mathcal{D}_{val}$, $\mathcal{D}_{test}$.

IV. PHƯƠNG PHÁP

Chúng tôi đề xuất một hệ thống giải quyết đồng tham chiếu cho văn bản tiếng Việt theo cấu trúc được thể hiện ở hình 2.

A. Pha Tiền xử lý dữ liệu

Trước khi đưa vào mô hình, dữ liệu văn bản thô được tiền xử lý nhằm đảm bảo tính nhất quán và phù hợp với bài toán gán nhãn chuỗi. Quy trình bao gồm các bước sau:

- **Làm sạch văn bản:** Chuyển toàn bộ văn bản về chữ thường, loại bỏ các dòng không cần thiết (ví dụ như #color hoặc #tokenization) và chuẩn hóa khoảng trắng.
- **Tokenization:** Văn bản được tách từ bằng thư viện *underthesea*, sau đó tiếp tục được mã hóa bằng tokenizer của mô hình encoder tiền huấn luyện để chuyển thành các đơn vị subword. Sau bước này, văn bản T được biểu diễn dưới dạng chuỗi token $w_1, w_2, \dots, w_n$.
- **Gán nhãn BIO:** Bài toán nhận diện mention được mô hình hóa như một bài toán gán nhãn chuỗi sử dụng sơ đồ BIO theo chuẩn thông dụng [5]. Với mỗi token w_i , nhãn y_i được xác định như sau:

$$y_i \in \{B-M, I-M, O\},$$

trong đó:

- B-M biểu thị token bắt đầu của một mention,
- I-M biểu thị token nằm bên trong một mention,
- O tương ứng với các token không thuộc mention nào.

B. Giai đoạn 1: Nhận diện đề cập

Giai đoạn này đóng vai trò quan trọng trong việc tìm ranh giới các cụm từ chỉ người trong văn bản kể chuyện.

- 1) **Chia nhỏ văn bản:** Văn bản được chia thành các đoạn có độ dài tối đa 512 subwords để phù hợp với giới hạn đầu vào của mô hình encoder.
- 2) **Mã hóa và Dự đoán:** Hệ thống sử dụng mô hình *AutoModelForTokenClassification* để trích xuất đặc trưng subword và dự đoán nhãn BIO cho từng token.
- 3) **Hậu xử lý:** Các nhãn dự đoán được đồng bộ lại để xác định chính xác danh sách các thực thể (mention) kèm theo vị trí bắt đầu và kết thúc (*start_char*, *end_char*).

C. Giai đoạn 2: Giải quyết đồng tham chiếu

Sau khi xác định được danh sách các thực thể, hệ thống thực hiện liên kết chúng để tạo thành các chuỗi đồng tham chiếu (coreference chains).

• Cấu trúc dữ liệu huấn luyện:

Gọi $E = \{m_1, m_2, \dots, m_k\}$ là tập hợp các đề cập (mentions) được trích xuất. Mỗi mention m_j được định nghĩa bởi một bộ:

$$m_j = (s_j, e_j, \text{eid}_j)$$

Trong đó:

- s_j, e_j : Chỉ số token bắt đầu và kết thúc.
- eid_j : Mã định danh thực thể (Entity ID).

Tập hợp các mention có cùng eid sẽ tạo thành một cụm vàng (gold cluster) C_n :

$$C_n = \{m_j \in E \mid \text{eid}_j = n\}$$

- **Trích xuất đặc trưng:** Với mỗi cặp (m_i, m_j) , hệ thống cần xác định xem chúng có cùng chỉ đến một thực thể hay không. Mỗi đề cập được ánh xạ thành một vector biểu diễn ngữ nghĩa bằng cách trích xuất các hidden states tương ứng từ encoder. Các vector này mã hóa thông tin về: ngữ cảnh xung quanh đề cập, ngữ nghĩa của cụm từ, mối quan hệ ngữ cảnh giữa các đề cập trong câu và đoạn văn.
- **Chấm điểm cặp:** Để quyết định hai đề cập có đồng tham chiếu hay không, hệ thống sử dụng một mạng thần kinh đa tầng (MLP) nhằm ước lượng xác suất liên kết giữa cặp (m_i, m_j) . Đầu vào của MLP bao gồm:
 - vector nhúng của đề cập m_i ,
 - vector nhúng của đề cập m_j ,
 - vector hiệu tuyệt đối (difference) $|m_i - m_j|$ nhằm biểu diễn mức độ khác biệt ngữ nghĩa,
 - thông tin khoảng cách vị trí (distance) giữa hai đề cập trong văn bản,
 - và đặc trưng trùng lặp chuỗi (same string).
- **Gom cụm:** Sau khi đã tính toán xác suất đồng tham chiếu cho các cặp đề cập, hệ thống tiến hành gom cụm để tạo thành các chuỗi đồng tham chiếu hoàn chỉnh. Cụ thể, nếu xác suất liên kết giữa hai đề cập vượt qua một ngưỡng định trước ($P > \tau$), hai đề cập này được xem là cùng một thực thể.

Thuật toán Union-Find được sử dụng để hợp nhất các đề cập có liên kết mạnh, đảm bảo tính bắc cầu (nếu m_1 liên kết với m_2 và m_2 liên kết với m_3 thì cả ba thuộc cùng một cụm), tạo ra các cụm cuối cùng một cách hiệu quả về mặt tính toán. Mỗi cụm thu được tương ứng với một thực thể duy nhất, là một nhân vật trong câu chuyện được nhắc đến nhiều lần dưới các hình thức khác nhau.

V. THỰC NGHIỆM

A. Mô hình

Trong đề án này, chúng tôi khảo sát một số kiến trúc encoder dựa trên Transformer, bao gồm cả mô hình đơn ngôn ngữ và đa ngôn ngữ, nhằm nghiên cứu ảnh hưởng của các kiểu biểu diễn ngữ cảnh khác nhau đối với hai bài toán nhận diện thực thể và giải quyết đồng tham chiếu.

Các mô hình được lựa chọn đều là những kiến trúc phổ biến, đã được sử dụng rộng rãi trong các bài toán xử lý ngôn

ngữ tự nhiên, đồng thời có sự khác biệt rõ ràng về dữ liệu tiền huấn luyện và cách biểu diễn ngôn ngữ, qua đó tạo điều kiện thuận lợi cho việc so sánh và phân tích.

- **PhoBERT [6]:** mô hình Transformer đơn ngôn ngữ cho tiếng Việt, được tiền huấn luyện trên tập dữ liệu lớn với quy trình tách từ, phù hợp để khảo sát vai trò của thông tin ngôn ngữ đặc thù trong các tác vụ xử lý tiếng Việt.
- **XLM-RoBERTa [7]:** mô hình đa ngôn ngữ được tiền huấn luyện trên dữ liệu quy mô lớn, cho phép khai thác biểu diễn ngữ cảnh ở mức subword và hỗ trợ nhiều ngôn ngữ khác nhau, từ đó cung cấp góc nhìn so sánh giữa tiếp cận đơn ngôn ngữ và đa ngôn ngữ.
- **DeBERTa v3 [8]:** mô hình Transformer với kiến trúc cải tiến, được thiết kế nhằm tăng cường khả năng mô hình hóa quan hệ ngữ nghĩa và phụ thuộc ngữ cảnh, phù hợp để đánh giá tác động của các cơ chế attention nâng cao trong các tác vụ suy luận ngôn ngữ.

B. Độ đo đánh giá

Hệ thống được đánh giá theo hai pha: (1) nhận diện thực thể và (2) giải quyết đồng tham chiếu.

1) Pha nhận diện thực thể:

a) **Precision:** Độ chính xác (Precision) đo lường tỷ lệ các mention được hệ thống dự đoán là đúng trên tổng số mention mà hệ thống dự đoán:

$$\text{Precision} = \frac{|\mathcal{M}_{pred} \cap \mathcal{M}_{gold}|}{|\mathcal{M}_{pred}|}.$$

b) **Recall:** Độ bao phủ (Recall) phản ánh khả năng của hệ thống trong việc phát hiện đầy đủ các mention đúng, được tính bằng tỷ lệ giữa số mention dự đoán đúng và tổng số mention tham chiếu:

$$\text{Recall} = \frac{|\mathcal{M}_{pred} \cap \mathcal{M}_{gold}|}{|\mathcal{M}_{gold}|}.$$

c) **F1-score:** F1-score là trung bình điều hòa giữa Precision và Recall, được sử dụng để cân bằng giữa độ chính xác và độ bao phủ:

$$F1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}.$$

Trong đó, một mention được xem là dự đoán đúng nếu ranh giới của nó trùng khớp hoàn toàn với nhân tham chiếu.

2) **Pha giải quyết đồng tham chiếu:** Độ đo tiêu chuẩn theo thiết lập của shared task CoNLL-2012 [3].

a) **MUC:** Đánh giá dựa trên số liên kết cần thêm hoặc loại bỏ để ánh xạ các cụm dự đoán $\mathcal{C}_{pred}$ sang các cụm tham chiếu $\mathcal{C}_{gold}$:

$$\text{MUC} = \frac{\sum_{C \in \mathcal{C}_{gold}} (|C| - |\text{links}(C)|)}{\sum_{C \in \mathcal{C}_{gold}} (|C| - 1)}.$$

b) B^3 : Tính trên từng mention m dựa trên mức độ chồng lấp giữa cụm dự đoán $C_{pred}(m)$ và cụm tham chiếu $C_{gold}(m)$:

$$P_m = \frac{|C_{pred}(m) \cap C_{gold}(m)|}{|C_{pred}(m)|},$$

$$R_m = \frac{|C_{pred}(m) \cap C_{gold}(m)|}{|C_{gold}(m)|},$$

$$B^3 = \frac{1}{|\mathcal{M}|} \sum_{m \in \mathcal{M}} \frac{2P_m R_m}{P_m + R_m}.$$

c) $CEAF_{\phi_4}$: Tìm ánh xạ một-một π tối ưu giữa các cụm dự đoán và tham chiếu:

$$\pi^* = \arg \max_{\pi} \sum_{(C_p, C_g) \in \pi} \phi_4(C_p, C_g),$$

$$\phi_4(C_p, C_g) = |C_p \cap C_g|.$$

d) $CoNLL F1$: Điểm CoNLL F1 được tính bằng trung bình không trọng số của các độ đo thành phần:

$$CoNLL F1 = \frac{1}{3} (MUC + B^3 + CEAF_{\phi_4}).$$

C. Phân tích pipeline

Nhằm đánh giá mức độ đóng góp của từng thành phần trong hệ thống đề xuất, chúng tôi tiến hành các thí nghiệm ablation bằng cách lần lượt loại bỏ một số thành phần then chốt, đồng thời giữ nguyên các thiết lập còn lại. Các thí nghiệm này được thực hiện độc lập cho từng pha trong pipeline, bao gồm (a) pha nhận diện thực thể và (b) pha giải quyết đồng tham chiếu. Kết quả ablation cho mỗi pha được phân tích riêng nhằm làm rõ vai trò của các yếu tố cấu hình mô hình đối với hiệu năng tổng thể của hệ thống.

a) *Pha Nhận diện thực thể*: Bảng I trình bày kết quả ablation cho pha nhận diện thực thể.

Bảng I
KẾT QUẢ THỬ NGHIỆM PHA NHẬN DIỆN THỰC THỂ

Model	Precision	Recall	F1
PhoBERT	85.96	85.49	85.73
-word seg	84.19	84.88	84.53
XLM-RoBERTa	90.63	93.33	91.96
-word seg	88.99	92.97	90.94
DeBERTa v3	90.74	91.74	91.24
-word seg	88.47	92.95	90.65

Nhìn chung, việc loại bỏ bước tách từ tiếng Việt (-word seg) đều dẫn đến suy giảm hiệu năng trên tất cả các mô hình mặc dù sự chênh lệch không lớn. Điều này cho thấy các mô hình vẫn có thể học được thông tin ngữ cảnh hiệu quả ngay cả khi không thực hiện tách từ tiếng Việt trước khi đưa vào mô hình.

Tuy nhiên, *word segmentation* vẫn mang lại cải thiện hiệu năng nhất định, đặc biệt đối với PhoBERT. Cả ba mô hình đều đạt kết quả F1-score cao nhất khi áp dụng *word segmentation*.

Bảng II
KẾT QUẢ THỬ NGHIỆM PHA GIẢI QUYẾT ĐỒNG THAM CHIẾU

Model	MUC F1	B ³ F1	CEAF F1	CoNLL F1
PhoBERT				
Full model	96.08	40.20	50.53	62.27
-dist	92.54	39.67	48.57	60.26
-same	92.55	39.54	50.48	60.86
-diff	87.81	37.13	42.62	55.85
XLM-RoBERTa				
Full model	94.33	67.64	66.08	76.02
-dist	93.36	66.03	62.25	73.88
-same	93.79	67.77	64.95	75.50
-diff	89.88	64.50	58.96	71.12
DeBERTa v3				
Full model	93.15	50.60	57.16	66.97
-dist	92.43	50.05	55.28	65.92
-same	91.99	49.29	50.56	65.28
-diff	93.34	51.47	57.85	67.42

b) *Pha giải quyết đồng tham chiếu*: Đối với pha giải quyết đồng tham chiếu, kết quả ablation được trình bày trong Bảng II.

Quan sát trên cả ba mô hình cho thấy cấu hình *Full model* đạt điểm CoNLL cao nhất, ngoại trừ DeBERTa v3.

Việc loại bỏ đặc trưng khoảng cách giữa các thực thể (-dist) và thông tin khác biệt (-diff) đều gây suy giảm đáng kể hiệu năng, đặc biệt trên PhoBERT và XLM-RoBERTa, cho thấy hai đặc trưng này đóng vai trò then chốt trong việc mô hình hóa quan hệ đồng tham chiếu. Ngược lại, đặc trưng so khớp chuỗi ký tự (same string) có mức ảnh hưởng thấp hơn, thậm chí trong một số trường hợp còn giúp cải thiện nhẹ B³.

Đáng chú ý, với DeBERTa v3, cấu hình loại bỏ đặc trưng khác biệt (-diff) lại đạt điểm CoNLL cao nhất. Kết quả này cho thấy khả năng biểu diễn ngữ nghĩa mạnh mẽ của DeBERTa v3 có thể đã bao hàm phần lớn thông tin mà đặc trưng này cung cấp, dẫn đến hiện tượng dư thừa khi kết hợp cả hai.

D. Thiết lập mô hình cho pha suy diễn

Dựa trên kết quả ablation, chúng tôi lựa chọn cấu hình có điểm CoNLL cao nhất cho từng backbone để sử dụng trong pha suy diễn (inference). Cụ thể, PhoBERT và XLM-RoBERTa sử dụng cấu hình đầy đủ, trong khi DeBERTa v3 được suy diễn với cấu hình loại bỏ đặc trưng khác biệt (diff feature).

Bảng III
KẾT QUẢ SUY DIỄN CỦA CÁC MÔ HÌNH TRÊN TẬP KIỂM TRA

Model	Inference setup	MUC	B ³	CEAF	CoNLL
PhoBERT	Full	89.35	24.89	32.25	48.83
XLM-RoBERTa	Full	92.67	29.94	40.87	54.49
DeBERTa v3	-diff feature	91.30	21.34	36.97	49.87

Kết quả suy diễn trên tập kiểm tra cho thấy XLM-RoBERTa đạt hiệu năng tổng thể cao nhất với điểm CoNLL F1 vượt trội so với hai mô hình còn lại.

Điều này cho thấy khả năng biểu diễn ngữ cảnh mạnh mẽ của mô hình đa ngôn ngữ này giúp cải thiện đáng kể chất lượng liên kết đồng tham chiếu, đặc biệt trong các trường hợp yêu cầu khai thác ngữ cảnh dài và đa dạng. Tuy PhoBERT và

DeBERTa v3 vẫn đạt kết quả ổn định nhưng hiệu năng của hai mô hình này thấp hơn đáng kể trên độ đo CoNLL, cho thấy còn tồn tại những hạn chế nhất định trong việc tổng hợp thông tin toàn cục.

Dựa trên các kết quả này, **XLM-RoBERTa** được lựa chọn là mô hình tốt nhất cho hệ thống trong thiết lập suy diễn cuối cùng.

VI. TỔNG KẾT & HƯỚNG PHÁT TRIỂN

Trong nghiên cứu này, chúng tôi đã tiến hành so sánh toàn diện các mô hình encoder phổ biến cho bài toán nhận diện thực thể và giải quyết đồng tham chiếu tiếng Việt. Kết quả thực nghiệm cho thấy mô hình đa ngôn ngữ **XLM-RoBERTa** đạt lợi thế rõ rệt.

Trong tương lai, nghiên cứu có thể được mở rộng theo hướng kết hợp các mô hình đơn và đa ngôn ngữ trong một kiến trúc đa tầng, cũng như khai thác thêm tri thức ngoài văn bản nhằm giảm các lỗi đồng tham chiếu phức tạp. Điều này hứa hẹn cải thiện độ ổn định và khả năng tổng quát của hệ thống trên các tập dữ liệu thực tế đa dạng hơn.

TÀI LIỆU THAM KHẢO

- [1] H.-D. Tran, D.-V. Nguyen, and N. L.-T. Nguyen, “Coreference resolution for Vietnamese narrative texts,” in *Proceedings of the 38th Pacific Asia Conference on Language, Information and Computation*, N. Oco, S. N. Dita, A. M. Borlongan, and J.-B. Kim, Eds. Tokyo, Japan: Tokyo University of Foreign Studies, Dec. 2024, pp. 1408–1417. [Online]. Available: <https://aclanthology.org/2024.paclic-1.139/>
- [2] E. Hovy, M. Marcus, M. Palmer, L. Ramshaw, and R. Weischedel, “OntoNotes: The 90% solution,” in *Proceedings of the Human Language Technology Conference of the NAACL, Companion Volume: Short Papers*. New York City, USA: Association for Computational Linguistics, Jun. 2006, pp. 57–60. [Online]. Available: <https://aclanthology.org/N06-2015>
- [3] S. Pradhan, A. Moschitti, N. Xue, O. Uryupina, and Y. Zhang, “CoNLL-2012 shared task: Modeling multilingual unrestricted coreference in OntoNotes,” in *Joint Conference on EMNLP and CoNLL - Shared Task*, S. Pradhan, A. Moschitti, and N. Xue, Eds. Jeju Island, Korea: Association for Computational Linguistics, Jul. 2012, pp. 1–40. [Online]. Available: <https://aclanthology.org/W12-4501/>
- [4] I. Porada, X. Zou, and J. C. K. Cheung, “A controlled reevaluation of coreference resolution models,” in *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, N. Calzolari, M.-Y. Kan, V. Hoste, A. Lenci, S. Sakti, and N. Xue, Eds. Torino, Italia: ELRA and ICCL, May 2024, pp. 256–263. [Online]. Available: <https://aclanthology.org/2024.lrec-main.23/>
- [5] E. F. Tjong Kim Sang and F. De Meulder, “Introduction to the CoNLL-2003 shared task: Language-independent named entity recognition,” in *Proceedings of the Seventh Conference on Natural Language Learning at HLT-NAACL 2003*, 2003, pp. 142–147. [Online]. Available: <https://aclanthology.org/W03-0419/>
- [6] D. Q. Nguyen and A. Tuan Nguyen, “PhoBERT: Pre-trained language models for Vietnamese,” in *Findings of the Association for Computational Linguistics: EMNLP 2020*, T. Cohn, Y. He, and Y. Liu, Eds. Online: Association for Computational Linguistics, Nov. 2020, pp. 1037–1042. [Online]. Available: <https://aclanthology.org/2020.findings-emnlp.92/>
- [7] Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, and V. Stoyanov, “Roberta: A robustly optimized bert pretraining approach,” 2019. [Online]. Available: <https://arxiv.org/abs/1907.11692>
- [8] P. He, J. Gao, and W. Chen, “Debertav3: Improving deberta using electra-style pre-training with gradient-disentangled embedding sharing,” 2023. [Online]. Available: <https://arxiv.org/abs/2111.09543>